

Программный модуль для повторной идентификации объектов в видеопотоке с камер видеонаблюдения

Ключевые слова: видеонаблюдение, повторная идентификация, нейронные сети, RGB-IR, модальность

Аннотация

В работе проанализирована проблема автоматической идентификации человека в системах видеонаблюдения при переключении камер в ночной инфракрасный режим. Рассмотрены существующие подходы к кросс-модальной (RGB-IR) повторной идентификации человека в системах видеонаблюдения и проведен сравнительный анализ современных методов, использующих генеративные сети, семантические подсказки, структурный анализ и аугментацию данных. На основе выработанных критериев (Механизм выравнивания модальностей, Rank-1, mAP) выбран метод, использующий генерацию промежуточных представлений. Предложена архитектура программного модуля, включающая подсистему детекции и модифицированный алгоритм сопоставления признаков, устойчивый к потере цветовой информации. Определены направления дальнейших исследований и тестирования разработанного решения.

Введение

Активное распространение систем видеонаблюдения и круглосуточного мониторинга создает устойчивую потребность в автоматическом анализе видеоданных [1-3]. Ключевой задачей в этой области является повторная идентификация человека (Person Re-Identification, Re-ID) — процесс сопоставления изображений одного и того же человека с разных камер, непересекающихся по полю зрения.

Большинство современных камер видеонаблюдения в условиях недостаточной освещенности автоматически переключаются в режим инфракрасной съемки (IR-режим), что приводит к потере цветовой информации, на которую опираются стандартные алгоритмы повторной идентификации. Исследования показывают, что точность базовых моделей при смене спектра с видимого (RGB) на инфракрасный падает на 30–40% [4]. Задача кросс-модальной идентификации в условиях смены RGB-IR режимов съемки называется Visible-Infrared ReID (VI-ReID). Существующие методы пытаются решить эту проблему с помощью генеративных сетей (GAN), механизмов внимания и аугментации данных [5], однако многие из них представлены только теоретическими схемами или программным кодом осуществления обучения и тестирования на определенных наборах данных, что делает такие методы сложными для внедрения в реальные системы.

Объектом данного исследования является процесс повторной идентификации человека в видеопотоке с распределенных камер. Предметом исследования выступает

устойчивость методов идентификации к условиям изменения модальности (смены цветового спектра съемки с RGB на IR).

Целью работы является разработка программного модуля для повторной идентификации человека, устойчивого к переключению режимов съемки. Для достижения цели были решены следующие задачи:

1. Проведен сравнительный анализ подходов к улучшению точности кросс-модальной идентификации.
2. Сформулированы критерии оценки эффективности методов.
3. Выполнен отбор наиболее перспективных архитектур.
4. Сформулированы рекомендации по построению программного модуля.

Обзор предметной области

Для решения задачи кросс-модальной идентификации был проведен поиск и анализ научных трудов за 2025 год, имеющих открытую реализацию или подробное описание архитектуры и протестированных на бенчмарке SYSU-MM01. Были рассмотрены следующие методы:

AGPI2 (Adaptive Generation of Privileged Intermediate Information)

Данный метод реализует подход к обучению, при котором генерируется виртуальное «привилегированное» промежуточное представление, служащее мостом между видимой и инфракрасной модальностями. Ключевой особенностью является использование генеративного модуля (GAN) только на этапе обучения. Это позволяет трансформировать признаки видимого спектра в пространство, близкое к инфракрасному, без использования генератора на этапе тестирования, что приводит к сложному и долгому обучению, но повышает точность при тестировании, не замедляя работу системы.[6]

FSRL (Fine-Grained Semantic Representation Learning)

Метод FSRL фокусируется на извлечении среднеуровневых признаков, содержащих детальную семантическую информацию об идентификации (детали одежды, форма тела). Архитектура включает модули нормализации и компенсации модальностей (MNC), агрегации промежуточных признаков (IFA) и семантически согласованного обучения (SAFL). Подход направлен на повышение точности за счет использования устойчивых к смене модальности деталей, но требует большего количества параметров.[7]

CECR-Net (Channel Enhanced Cross-modality Relation Network)

Метод реализует двухпоточную архитектуру, нацеленную на захват структурных отношений между частями тела, инвариантных к модальности (эффективно используется структурная информация тела, которая не меняется с изменением модальности, позы или освещения). Метод использует стратегию Channel-Enhanced Sharing (CES), где видимые изображения случайным образом преобразуются для имитации одноканальных ИК-изображений, что повышает устойчивость к вариациям цвета. Архитектура включает модули Intra-Relation Learning (IRL) и Cross-Relation Learning

(CRL), основанные на реляционных сетях (relation network), для моделирования структурных связей внутри и между модальностями соответственно.[8]

CSDN (CLIP-Driven Semantic Discovery Network)

CSDN использует предварительно обученную модель CLIP (Language-Image Pre-training) для интеграции высокоуровневой семантики (пол, атрибуты одежды) в визуальные признаки. Особенности реализации: Modality-specific Prompt Learner (MsPL) для генерации бимодальных (отдельно для RGB и IR) языковых описаний, Semantic Information Integration (SII) с механизмом внимания для объединения семантических деталей из V и I описаний, High-level Semantic Embedding (HSE) для встраивания богатых текстовых признаков в визуальные представления. Все указанные дополнительные модули используются только на этапе обучения, что сохраняет высокую скорость работы.[9]

MTRL (Modality-Transition Representation Learning)

Фреймворк MTRL использует сгенерированные промежуточные изображения как «передатчик» для выравнивания признаков видимого и инфракрасного спектров. Главная архитектурная особенность — отсутствие дополнительных параметров на этапе вывода. Улучшение качества достигается за счет использования специфических функций потерь (Modality-Aware Hierarchical Constraints Loss и Modality-Query Regularization Loss), которые основываются на сгенерированных изображениях, уменьшая различия между модальностями.[10] Использование генератора добавляет 16% ко времени обучения в сравнении с baseline методом, в качестве которого в исследовании используется SAAI.[11]

Для сравнения методов использовались следующие критерии:

Механизм выравнивания модальностей

Данный критерий отображает архитектурную особенность построения метода, направленную на уменьшение разрыва между признаками RGB и IR изображений. Это качественный критерий, определяющий, за счет чего достигается инвариантность: генерация промежуточных данных (GAN), использование семантических подсказок, структурный анализ частей тела или аугментация каналов. Выбор механизма напрямую влияет на сложность обучения и устойчивость к шуму.

Rank-1

Критерий Rank-1 показывает вероятность того, что верное изображение искомого человека окажется первым среди выборки по запросу.

Формула расчета Rank-1:

Пусть есть Q запросов. Для каждого запроса q система выполняет поиск по галерее и возвращает ранжированный список результатов, где 1-я позиция — самый похожий объект.

Проверяется, является ли результат на **первой позиции** релевантным (правильным):

$$\text{Rank-1}(q) = \text{rel}(1)$$

где $\text{rel}(k)$ — функция релевантности результата на k -й позиции:

Итоговая метрика **Rank-1 Accuracy** вычисляется как среднее по всем запросам:

$$\text{Rank-1} = \frac{1}{Q} \sum_{q=1}^Q \text{Rank-1}(q) = \frac{\text{Число запросов с правильным 1-м результатом}}{\text{Общее число запросов } Q}$$

Аналогичным образом для тестирования систем re-id при обучении зачастую вычисляются критерии Rank-N , $N \in \{5, 10, 20\}$, но самым важным из них является Rank-1, так как он наиболее применим на практике.

mAP

Метрика mAP (mean Average Precision) в задаче повторной идентификации отражает среднюю точность ранжирования по множеству запросов.

Формула расчета mAP:

Пусть есть Q запросов. Для каждого запроса q вычисляется **Average Precision (AP)**:

$$AP(q) = \frac{1}{K_q} \sum_{k=1}^N P(k) \cdot \text{rel}(k)$$

где:

- N — общее число изображений в галерее,
- $\text{rel}(k)$ —
- $P(k)$ —
- K_q — общее число релевантных изображений для запроса q в галерее.

Затем mAP вычисляется как среднее по всем запросам:

$$mAP = \frac{1}{Q} \sum_{q=1}^Q AP(q)$$

По mAP можно оценить общую способность алгоритма находить все релевантные результаты идентификации объекта и возвращать их на высокие позиции результатов поиска.

Сравнение метрик точности проводилось на общепринятом для задачи VIREld (Visible-Infrared Re-Identification) датасете SYSU-MM01, впервые представленном на конференции ICCV 2017 [12, 13]. В таблице приведены результаты тестирования в режиме All-Search: камеры RGB 1, 2, 4 и 5 используются для набора галереи, а ИК-

камеры 3 и 6 — для набора проб, при этом камеры 1, 2, 3 - внутри помещения, а камеры 4, 5 и 6 - наружные.

Результаты сравнения представлены в таблице 1.

Таблица 1. Сравнение аналогов

Аналог	Механизм выравнивания модальностей	Rank-1	mA P
AGPI2	Генерация виртуального промежуточного представления (GAN)	76.83%	71.56%
FSRL	Извлечение мелкозернистых признаков и структурных частей тела	76.95%	77.90%
CECR-Net	Аугментация каналов (CES) и реляционные сети	76.83%	71.56%
CSDN	Интеграция семантики через CLIP и Prompt Learning	76.7%	73.0%
MTRL	Использование промежуточного изображения-передатчика и структурных потерь	76.80%	78.36%

Выводы по итогам сравнения

На основе проведенного анализа можно сделать следующие выводы:

Методы **AGPI2** и **MTRL** демонстрируют наиболее эффективный подход для реальных систем видеонаблюдения. Они используют сложные вычисления (генерацию изображений) только на этапе обучения, что позволяет достигать высокой точности, не замедляя работу системы на этапе вывода.

Метод **CSDN**, использующий мультимодальную модель CLIP, показывает перспективность интеграции текстовых описаний. Это дает высокую точность, однако качество работы зависит от предобученной модели CLIP и может быть ограничено “грубостью” семантических токенов.

Метод **FSRL** показывает высокие результаты по метрике точности за счет учета мелких деталей, но платит за это увеличением числа параметров (с 56М до 76М) и снижением FPS [6], что может быть критично для встраиваемых систем.

CECR-Net предлагает подход к аугментации данных без использования GAN, что снижает вычислительные затраты на обучение, а также дает довольно низкое время отклика (2.6 мс [7]) но демонстрирует чуть более низкие показатели точности по сравнению с другими аналогами.

Для задач, требующих работы в реальном времени с ограниченными ресурсами, наиболее предпочтительными архитектурами являются те, которые выносят вычислительную сложность на этап обучения (AGPI2, MTRL).

Выбор метода решения

Реализуемый программный модуль должен представлять из себя полноценный, стандартный для применяемого на практике re-id модуля, пайплайн (конвейер), включающий детекцию, выделение признаков и сопоставление с галереей ранее идентифицированных объектов. В данном исследовании объектами являются люди в кадрах видеозаписи.

Для детекции будет применена модель YOLO, зарекомендовавшая себя как прооверенный временем и постоянно обновляемый фреймворк для детекции и трекинга объектов [14].

Решение задачи re-id: За основу метода идентификации будет взят один из методов, использующих генеративный подход: **AGPI2** или **MTRL** с модификацией процедуры обучения с помощью добавления аугментации данных или объединения подходов, используемых в данных методах.

Для подтверждения эффективности выбранного метода необходимо провести следующие эксперименты:

- Тестирование на стандартном датасете SYSU-MM01 по критериям точности (значение Rank-1, mAP) в режиме All Search. Ожидаются значения Rank-1 > 76%, mAP > 75%.
- Замер времени отклика полученного программного модуля для оценки применимости в системах видеонаблюдения реального времени. Ожидается сохранение скорости на уровне baseline методов, не использующих генеративный подход для обучения.
- Визуализация распределения признаков (t-SNE) для видимых и инфракрасных изображений одной персоны до и после применения предложенного метода обучения. Ожидается более плотная кластеризация признаков одной личности независимо от спектра.

Описание метода решения

Разрабатываемый программный модуль представляет собой конвейер (pipeline) обработки видеоданных, состоящий из трех основных этапов: детекция, извлечение признаков и сопоставление.

1. Модуль детекции

Первичная обработка видеопотока осуществляется с помощью модели YOLO (You Only Look Once) [14]. Данный фреймворк выбран благодаря оптимальному балансу скорости и точности. Модуль принимает на вход кадр видеопотока и возвращает координаты ограничивающих рамок (bounding boxes) для всех обнаруженных людей. Изображения

внутри рамок вырезаются, масштабируются до фиксированного размера (например, 256x128 пикселей) и передаются в модуль извлечения признаков.

2. Модуль извлечения признаков

Модуль извлечения признаков основывается на выбранном генеративном подходе, осуществляющем повторную идентификацию человека, с помощью адаптации и модификации архитектур, описанных в AGPI2/MTRL. Идеи по построению архитектуры модуля:

- В качестве основной сверточной сети, используемой моделью будет выбрана CHC ResNet50.
- Процесс обучения будет состоять из двух потоков: первый поток обрабатывает реальные изображения, второй поток на основе GAN создает “виртуальные” признаки, имитирующие переход между RGB и IR спектрами.
- Модификация модели обучения будет основана на аугментации данных, которая может использовать подход метода CECR-Net со случайным выбором цветового канала подваемого изображения для имитации одноканального IR режима.
- В качестве функции потерь будет использоваться комбинация, описанная для MTRL: Modality-Aware Hierarchical Constraints Loss и Modality-Query Regularization Loss.
- На выходе должен формироваться вектор признаков, слабо зависящих от цветовых характеристик обрабатываемых изображений.

3. Модуль сопоставления и ранжирования

Полученный вектор признаков должен сравниваться с галереей ранее сохраненных векторов, полученных при идентификации предыдущих изображений. Для сопоставления id должен осуществляться расчет меры близости, например на основе косинусного расстояния.

Исследование метода решения

Для подтверждения эффективности предложенного подхода запланировано проведение экспериментального исследования.

Экспериментальное определение точности модифицируемой архитектуры обучения сети будет определяться с помощью вычисления метрик Rank-1 и mAP на наборе данных SYSU-MM01 [12, 13] в режиме All Search.

План экспериментов

1. Обучение базовой модели (ResNet-50) без использования кросс-модальных техник для получения baseline-значений.
2. Обучение модели с внедренным генеративным модулем (предложенный метод).
3. Сравнение полученных метрик.
4. Замер времени инференса (время отклика) на одном кадре.

5. Визуализация пространства признаков с помощью алгоритма t-SNE для оценки качества кластеризации RGB и IR образов одной персоны.

Заключение

В рамках работы над статьей были решены поставленные задачи:

1. Проведен анализ предметной области, подтвердивший потерю точности классических методов в задаче Visible-Infrared ReID.
2. Сформулированы критерии оценки (механизм выравнивания модальностей, Rank-1, mAP), позволяющие объективно сравнивать алгоритмы.
3. На основе сравнения пяти современных аналогов (AGPI2, FSRL, CECR-Net, CSDN, MTRL) выявлено, что наиболее перспективными для практического применения являются методы, выносящие дополнительную вычислительную нагрузку, связанную с модификацией архитектуры для задачи VI-ReID, на этап обучения.
4. Выбрана архитектура метода повторной идентификации на базе генеративного подхода и описана структура программного модуля, включающая детектор YOLO и модифицированный экстрактор признаков.

Дальнейшая работа будет направлена на программную реализацию модуля re-id, обучении нейронной сети на датасете SYSU-MM01 и интеграции решения в тестовую систему видеонаблюдения для проверки показателей производительности в реальных условиях эксплуатации.

Список использованных источников

1. Статья о видеоаналитике на мировом рынке. // URL: [https://www.tadviser.ru/index.php/Статья:Видеоаналитика_\(мировой_рынок\)](https://www.tadviser.ru/index.php/Статья:Видеоаналитика_(мировой_рынок))
2. Видеоаналитика в цифрах. // URL: <https://www.techportal.ru/security/video-analytics/rynok-v-tsifrakh/#first>
3. Video Surveillance And VSaaS Market (2024 - 2030) // URL: <https://www.grandviewresearch.com/industry-analysis/video-surveillance-industry>
4. Deep Learning for Person Re-identification: A Survey and Outlook. Mang Ye, Jianbing Shen, Gaojie Lin, Tao Xiang, Ling Shao, Steven C. H. Hoi // URL: <https://arxiv.org/abs/2001.04193>
5. Person Re-Identification with RGB-D and RGB-IR Sensors: A Comprehensive Survey. Md Kamal Uddin, Amran Bhuiyan, Fateha Khanam Bappee, Md Matiqul Islam, Mahmudul Hasan // URL: <https://www.mdpi.com/1424-8220/23/3/1504>
6. Adaptive Generation of Privileged Intermediate Information for Visible-Infrared Person Re-Identification. Mahdi Alehdaghi, et al. // URL: <https://ieeexplore.ieee.org/abstract/document/10887926>
7. Fine-Grained Semantic Representation Learning for Visible-Infrared Person Re-Identification. Qiang Wang, et al. // URL: <https://ieeexplore.ieee.org/abstract/document/11072047>
8. Song, W., Wang, X., Wu, W. et al. Channel enhanced cross-modality relation network for visible-infrared person re-identification. Appl Intell 55, 4 (2025) // URL: <https://doi.org/10.1007/s10489-024-06057-x>

9. CLIP-Driven Semantic Discovery Network for Visible-Infrared Person Re-Identification. Xiaoyan Yu, et al. // URL: <https://ieeexplore.ieee.org/abstract/document/10855601>
10. Modality-Transition Representation Learning for Visible-Infrared Person Re-Identification. Chao Yuan, et al. // URL: <https://arxiv.org/abs/2511.02685>
11. GitHub репозиторий baseline метода SAAI. // URL: <https://github.com/xiaoye-hhh/SAAI>
12. Ancong Wu, Wei-Shi Zheng, Hong-Xing Yu, Shaogang Gong, Jianhuang Lai, “RGB-Infrared Cross-Modality Person Re-Identification”, In International Conference on Computer Vision (ICCV), 2017. // URL: https://openaccess.thecvf.com/content_iccv_2017/html/Wu_RGB-Infrared_Cross-Modality_Person_ICCV_2017_paper.html
13. GitHub репозиторий датасета SYSU-MM01 // URL: <https://github.com/wuancong/SYSU-MM01>
14. The YOLO Framework: A Comprehensive Review of Evolution, Applications, and Benchmarks in Object Detection. Momina Liaqat Ali, Zhou Zhang // URL: <https://www.mdpi.com/2073-431X/13/12/336>